

- 并发程序在进行协作时能够实现:
 - 共享逻辑地址空间:包括代码段+数据段
 - 线程的实现
 - 共享资源
 - 通过文件、消息等实现
 - 但是并发访问可能导致资源状态的不一致

- Q:如何确保共享同一逻辑地址空间的协作进程有序执行,不产生资源状态的不一致?
 - 即:在并发程序推进速度不一致、不可预测的情形下,确保多进程推进的相对次序是按照预期推进的,从而确保并发程序的正确性?

4.1 同步与互斥的概念

4.1 同步与互斥的概念

- 在多道程序系统中,进程之间的相互制约关系体现在如下两个方面:
 - 直接制约关系:合作进程之间产生的制约关系
 - 或称协作关系,需要同步 (synchronization)
 - 间接制约关系: 共享资源产生的制约关系。
 - 或称竞争关系,需要互斥 (mutual exclusion)

与时间有关的错误例子1:结果不唯一

■ 现有订票系统,x为存储某班次飞机剩余票数的存储区域

A:

- 1. R1 = x;
- 2. if (R1 > = 1) {
- 3. R1--;
- 4. x=R1;
- 5. {出票}
- **6.** }

B:

- 1. R2=x;
- 2. if (R2 > = 1){
- 3. R2--;
- 4. x=R2;
- 5. {出票}
- **6.** }

与时间有关的错误例子1: 结果不唯一

进程A:

```
1. R1=x;
2. if (R1>=1) {
3. R1--;
4. x=R1;
5. {出票}
6. }
```

如果先执行A再执行B,则x值最终减少2, A、B输出的x不同。

进程B:

```
1. R2=x;
2. if (R2>=1){
3. R2--;
4. x=R2;
5. {出票}
6. }
```

1

与时间有关的错误例子1: 结果不唯一

进程A:

- 1. R1 = x;
- 2. if (R1 > = 1) {

3. R1--;

- 4. x=R1;
- 5. {出票}
- **6**. }

进程B:

- 1. R2=x;
- 2. if (R2 > = 1){
- 3. R2--;
- 4. x=R2;
- 5. {出票}
- **6**. }

若按顺序R1=x;R2=x;R1--;x=R1;R2=R2--;x=R2;则x值最终减少1,A、B输出的x是相同的。

与时间有关的错误例子1: 结果不唯一

- A:
 - 1. R1 = x;
 - 2. if (R1 > = 1) {
 - 3. R1--;
 - 4. x=R1;
 - 5. {出票}
 - **6**. }

- B:
 - 1. R2=x;
 - 2. if (R2 > = 1){
 - 3. R2--;
 - 4. x=R2;
 - 5. {出票}
 - 6.
- 这种错误称为"与时间有关的错误",有些地方称为 (race condition)
- 产生原因
 - 没有互斥使用共享变量,或者说没有在某进程进入时禁止另一个进程的进入。
 - 我们称以上例子中的错误为*结果不唯一*的错误

与时间有关的错误例子2:永远等待

- alloc和free为申请和归还资源的函数,进程在申请和释放时候调用它们。
- x为当前可用的总主存量,B为申请数量:

```
      void alloc(int B)
      void free(int B)

      {
      while(B>x)
      x=x+B;

      {将申请进程设置进入等
      {修改主存分配表}

      特队列,等待主存资源}
      {唤醒等待主存资源的进程}

      x=x-B;
      }

      {修改主存分配表}
      }

      {申请进程获得主存资源}
      }
```

与时间有关的错误例子2:永远等待

```
进程A:
void alloc(int B)
{
    while(B>x)
    {将申请进程设置进入等待
    队列,等待主存资源}
    x=x-B;
    {修改主存分配表}
    {申请进程获得主存资源}
}
```

```
进程B:
void free(int B)
{
    x=x+B;
    {修改主存分配表}
    {唤醒等待主存资源的进程}
}
```

与时间有关的错误例子2:永远等待

```
进程A:
void alloc(int B)
{
while(B>x)
```

```
{将申请进程设置进入等
待队列,等待主存资源}
x=x-B;
{修改主存分配表}
{申请进程获得主存资源}
```

```
进程B:
void free(int B)
{
    x=x+B;
    {修改主存分配表}
    {唤醒等待主存资源的进程}
}
```

如果某个时刻B>x,进程A调用alloc,在执行while之后,{申请...等待...}之前,进程B进入处理器,调用了free,则由于A还未来得及进入排队,则不会被唤醒,此后A进程进入等待队列,但不再有人唤醒A。

4.1.1 临界资源与临界区

临界资源:

- 一段时间内仅允许一个进程使用的资源称为临界资源。 (Critical Resource)
- 如:打印机、共享变量。

临界区:

- 进程中访问临界资源的那段代码称为临界区,又称临界段。
- 同类临界区:
 - 所有与同一临界资源相关联的临界区。

临界资源访问过程

- 一般包含四个部分:
- 1.进入区
 - 检查临界资源访问状态
 - 若可访问,设置临界资源被访问状态
- 2.临界区
 - 访问临界资源代码
- 3.退出区
 - 清除临界资源被访问状态
- 4.剩余区
 - 其他部分

访问临界资源应遵循的原则

- 1. 空闲让进
 - 若无进程处于临界区时,应允许一个进程进入临界区,且一次至多允许一个进程进入。
- 2. 忙则等待
 - 当已有进程进入临界区,其他试图进入的进程应该等待。
- 3. 有限等待
 - 应保证要求进入临界区的进程在有限时间内进入临界区。也蕴含着有限使用的意思!
- 4. 让权等待
 - 当进程不能进入自己的临界区时,应释放处理机,不至于造成饥饿甚至死锁。

访问临界资源应遵循的原则cont.

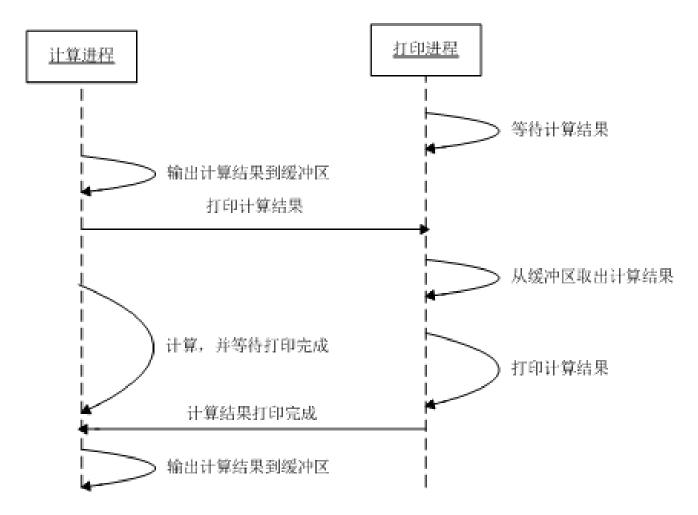
- 互斥原则, mutual exclusion
 - 如果进程Pi在其临界区内执行,那么其他进程都不能在其临界区执行
- 推进原则, Progress
 - 如果没有进程在其临界区内执行,并且有进程需要进入临界区,那么只有那些不在剩余区执行的进程可以参与选择,以便确定谁能下次进入临界区,而且这种选择不能无限推迟。
- 有限等待, bounded waiting
 - 从一个进程作出进入临界区的请求,直到这个请求允许为止,其他 进程允许进入临界区的次数具有上限。

4.1.2 同步与互斥

- 同步(synchronization):
 - 多个相互合作的进程在一些关键点上可能需要 互相等待或互相交换信息,这种相互制约关系 称为进程同步。
 - 不确定中蕴含了确定性!
- 同步例子: 计算进程与打印进程共享一个 单缓冲区。



• 计算进程与打印进程的同步



互斥

- 互斥(mutual exclusion):相互制约关系
 - 当一个进程正在使用某资源时,其他希望使用该资源的进程必须等待
 - 当该进程用完资源并释放后,才允许其他进程去访问此资源

4.2 互斥的实现方法

4.2 互斥的实现方法

- 互斥的实现
 - 软件方法
 - 硬件方法
 - 更高级的抽象方法
- 这里我们讨论的并发进程所处环境是
 - 单处理器计算机系统 (主)
 - 共享主存的多处理计算机系统 (辅)

4.2.1 互斥的软件实现方法

- 假设:有两个进程P0和P1
 - P0、P1为并发进程
 - P0、P1互斥地共享某个临界资源
 - P0、P1不断工作,每次使用该资源一个有限的时间间隔。

算法1的思想

- 朴素想法:设置一个开关变量turn
 - turn为公用整型变量,用来指示允许进入临界区的进程标识。
 - 对于P0,若turn为0,则允许进程P0进入临界区;否则循环检查该变量,直到turn变为本进程标识0;
 - 在退出区,修改允许进入进程的标识为1。 进程P1的算法与此类似。

算法1的描述

■ 算法1存在的问题

- 此算法可以保证互斥访问临界资源,但两个进程在 调度中必须以交替次序进入临界区。
- P0执行完一次循环之后,P1若不被调度执行,P0 也无法继续运行;
- 此算法不能保证实现空闲让进准则。

算法2的思想

- 算法1的程序问题在于
 - 使用标识后设置了标识,导致标识与初始不一致, 从而造成两程序的依赖关系
 - 注意: 这种依赖关系在后续某些问题中是有价值的!。
- 改进思想: 消除依赖关系
 - 设置彼此独立的标志数组flag[i]表示进程i是否在临界区中执行,初值均为假。
 - 在每个进程访问临界资源之前,先检查另一个进程 是否在临界区中,若不在,则修改本进程的临界区 标志为真,并进入临界区,
 - 在退出临界区时,修改本进程临界区标志为假。

算法2的描述

```
enum bool {false, true}; bool flag[2]={false, false};
```

```
P0: {
                                    P1: {
     do {
                                          do {
          while (flag[1]);
                                               while (flag[0]);
          flag[0] = true;
                                               flag[1] = true;
          进程P0的临界区代码CS0;
                                               进程P1的临界区代码CS1;
          flag[0] = false;
                                               flag[1] = false;
          进程PO的其他代码;
                                               进程P1的其他代码;
     while(true)
                                          while(true)
```

■ 算法2的问题:

- 此算法解决了空闲让进的问题,但有可能两个进程同时进入临界区。
- 当两个进程都未进入临界区时,它们各自的访问标志值都为false,若此时刚好两个进程同时都想进入临界区,并且都发现对方标志值为false,两个进程可以同时进入了各自的临界区,这就违背了临界区的访问原则忙则等待。

算法3的思想

- 算法2的程序问题在于
 - 检测点过早,标志flag[0]与flag[1]之间没有 形成互反,导致进入条件均可满足
- 算法3的改进:
 - 延迟检测点,本算法仍然设置标志数组flag[i],标志用来表示进程;是否计划进入临界区,即一种意愿。
 - 在每个进程访问临界资源之前,先将自己的标志设置为true,表示进程希望进入临界区
 - 然后再检查另一个进程的标志,若另一个进程的标志为true,则进程等待,否则进入临界区。

算法3的描述

```
ehum bool {false, true};
bool flag [2] ={false, false};
```

```
P0: {
    do {
        flag[0] = true;
        while (flag[1]);

    进程P0的临界区代码CS0;
    flag[0] = false;
    进程P0的其他代码;
    }
    while(true)
    }
```

算法3的问题:

- 该算法可以有效地防止两个进程同时进入临界区,但存在两个进程都进不 了临界区的问题。
- 当两个进程同时想进入临界区时,它们分别将自己的标志位设置为true, 并且同时去检查对方的状态,发现对方也要进入临界区,于是双方互相谦 让,结果谁也进不了临界区。违背了让权等待原则

算法4的思想: Dekker算法

- 算法3的问题在于
 - 预期进入临界区标识Flag,无法识别当前已经进入的其他进程情况
- 算法4的改进:
 - 荷兰数学家T. Dekker提出了一种Dekker算法,解决此问题。
 - 本算法的基本思想是算法3和算法1的结合。是一个 正确的算法。
 - 标志数组flag[]表示进程是否希望进入临界区或是 否正在临界区中执行。
 - 还设置了一个turn变量,用于指示允许进入临界区的进程标识。

算法4的描述

P1:

```
enum bool {false, true};
 bool flag [2] = \{false, false\};
int turn = 0 或者 1;
P0:
      do{
         flag[0] = true;
2.
3.
         while (flag[1]){
4.
           if (turn!=0){
5.
              flag[0] = false;
              while (turn!=0);
6.
              flag[0] = true;
7.
8.
9.
```

进程P0的临界区代码CS0;

turn = 1;

} while (true)

flag[0] = false;

进程PO的其他代码;

10.

11.

12.

13.

14.

```
do{
1.
2.
        flag[1] = true;
        while (flag[0]){
3.
           if (turn!=1){
4.
5.
             flag[1] = false;
             while (turn!=1);
6.
             flag[1] = true;
7.
8.
9.
        进程P1的临界区代码CS1;
10.
11.
        turn = 0;
12.
        flag[1] = false;
13.
        进程P1的其他代码;
     } while (true)
14.
```

讨论

1. 会不会出现无法推进呢,例如,如果等待在p0第一层while循环里如何? 如果等待在p0第二层循环里如何?

 为什么需要if(turn! =0)呢? 如果没有 会怎样?

讨论问题2

```
enum bool {false, true};
bool flag [2] ={false, false};
int turn =0;

P0:

1. do{
2. flag[0] = true;
3. while (flag[1]){
4. {
```

```
hile (flag[1]){

{

    flag[0] = false;

    while (turn!=0);

    flag[0] = true;
}
```

```
10. 进程P0的临界区代码CS0;
11. turn = 1;
12. flag[0] = false;
```

```
13. 进程P0的其他代码;
14. } while (true)
```

5.

6.

7.

8.

9.

P1:		

- 2. flag[1] = true;3. while (flag[0]){
- 4. {5. flag[1] = false;
- 6. while (turn!=1);
- 7. flag[1] = true;
- 8. } 9. }

do{

1.

- 10. 进程P1的临界区代码CS1;
- 11. turn = 0;
- 12. flag[1] = false;
- 13. 进程P1的其他代码;
- **14.** } while (true)

这里有问题吗? --1

```
enum bool {false, true};
 bool flag [2] = \{false, false\};
int turn =0;
P0:
                                        P1:
     do{
                                        1.
                                              do{
        flag[0] = true;
2.
                                        2.
                                                 flag[1] = true;
3.
        while (flag[1]){
                                                 while (flag[0]){
                                        3.
4.
           if (turn!=0){
                                                   if (turn!=1){
                                        4.
5.
             flag[0] = false;
                                        5.
                                                      flag[1] = false;
             while (flag[1]);
6.
                                                      while (flag[0]);
                                        6.
7.
             flag[0] = true;
                                                      flag[1] = true;
                                        7.
8.
                                        8.
9.
                                        9.
10.
        进程P0的临界区代码CS0;
                                        10.
                                                 进程P1的临界区代码CS1;
11.
        turn = 1;
                                        11.
                                                 turn = 0;
        flag[0] = false;
12.
                                        12.
                                                 flag[1] = false;
        进程PO的其他代码;
13.
                                        13.
                                                 进程P1的其他代码;
```

14.

} while (true)

14.

} while (true)

这里有问题吗? --2(小作业)

```
enum bool {false, true};
bool flag [2] = \{false, false\};
int turn =0;
P0:
     do{
        flag[0] = true;
2.
3.
        while (turn! = 0){
4.
5.
             flag[0] = false;
             while (flag[1]);
6.
7.
             flag[0] = true;
8.
9.
        进程P0的临界区代码CS0;
10.
11.
        turn = 1;
        flag[0] = false;
12.
        进程PO的其他代码;
13.
```

14.

} while (true)

```
P1:
1.
     do{
2.
        flag[1] = true;
        while (turn ! = 1){
3.
4.
5.
             flag[1] = false;
             while (flag[0]);
6.
7.
             flag[1] = true;
8.
9.
10.
        进程P1的临界区代码CS1;
11.
        turn = 0;
12.
        flag[1] = false;
13.
        进程P1的其他代码;
     } while (true)
14.
```

算法5的描述:Peterson算法

■ 1981年,G. L. Peterson 给出了一种更为简单的实现算法 enum boolean {false, true}; boolean flag[2] = {false, false}; int turn;

```
P0:
  do
    flag[0] = true;
    turn = 1;
    while (flag[1] \&\&turn = = 1)
    进程PO的临界区代码CSO;
    flag[0] = false;
    进程PO的其他代码;
  } while (true)
```

```
P1:
  do
    flag[1] = true;
    turn = 0;
    while (flag[0] \&\&turn = = 0)
    进程P1的临界区代码CS1;
    flag[1] = false;
    进程P1的其他代码;
  } while (true)
```

4.2.2 硬件方法

- 软件算法实现互斥是较为困难的
 - 最大的问题是对临界区的检测与设置动作很难作为一个整体来实现
 - 软件一条语句可能会被拆分
- 用硬件方法实现互斥的主要思想是
 - 在单处理器情况下,并发进程是交替执行的, 因此只需要保证检查操作与修改操作不被中 断即可,因此可以对关键部分进行硬件实现
 - 关中断方法
 - 原子指令方法

1、关中断方法

- 当进程执行临界区代码时,要防止其他 进程进入其临界区访问,最简单的方法 是关中断。Why?
- 关中断
 - 能保证当前运行进程将临界区代码顺利执行 完,从而保证了互斥的正确实现,然后再允 许中断。
 - 现代计算机系统都提供了关中断指令。
 - 中断响应将延迟到中断启用之后

用关中断方法实现互斥

```
--- 关中断;
临界区;
开中断;
```

关中断方法的不足

- 效率问题
 - 如果临界区执行工作很长,则无法预测中断响应的时间
 - 系统将处于暂停状态,无法响应事件
 - 限制了处理机交替执行程序的能力,执行的效率将会明显降低;
- 适用范围问题
 - 关中断不一定适用于多处理器计算机系统
 - 一个处理器关掉中断,并不意味着其他处理器也关闭中断, 不能防止进程进入其他处理器执行临界代码。
- 安全性问题:
 - 将关中断的权力交给用户进程则很不明智,若一个进程关中断之后不再开中断,则系统可能会因此终止甚至崩溃。

2、原子指令方法

- 许多计算机中提供了专门的硬件指令, 实现对字节内容的检查和修改或交换两个字节内容的功能。
- 使用这样的硬件指令就可以解决临界区 互斥的问题。
 - 测试设置方法
 - 对换指令方法

TS (Test-and-Set) 指令

■ TS指令的功能可描述如下:

```
boolean TS(boolean * lock)
{
    if (false == *lock){
        *lock = true;
        return false;
    }
    else
        return true;
}
```

```
boolean TS(boolean *lock)
{
    boolean old;
    old=*lock;
    *lock=true;
    return old;
}
```

用TS指令实现进程互斥

■ 为每个临界资源设置一个共享布尔变量 lock表示资源的两种状态: true表示正 被占用, false表示空闲。算法如下:

```
while TS(&lock);
进程的临界区代码CS;
lock=false;
进程的其他代码;
```

Swap指令 (或Exchange指令)

■ Swap指令的功能可描述如下:

```
Swap(boolean *a, boolean *b)
{
  boolean temp;
  temp=*a;
  *a=*b;
  *b=temp;
}
```

用Swap指令实现进程互斥

为每个临界资源设置一个共享布尔变量lock表示临界资源状态;再设置一个局部布尔变量key用于与lock交换信息。算法如下:

```
key=true;
while(false !=key) Swap(&lock, &key);
进程的临界区代码CS;
lock=false;// or Swap(&lock, &key);
进程的其他代码;
```

4.2.3 互斥锁机制

- 互斥锁是一个代表资源状态的变量,通常用0表示资源可用(开锁),用1表示资源已被占用(关锁)。
- 在使用临界资源前需先考察锁变量的值
 - 如果值为0则将锁设置为1 (关锁)
 - 如果值为1则回到第一步重新考察锁变量的值
 - 当进程使用完资源后,应将锁设置为0(开锁)。

锁原语

上锁

```
lock (w)
{
 while (w==1) ;//等待可锁状态
 w = 1;//加锁
}
```

■ 开锁

```
unlock (w)
{
 w = 0;//解锁
}
```

用互斥锁机制实现互斥

自旋锁

互斥锁

- 往往采用前面所介绍的硬件机制来实现
- 对于单处理器,为了提高效率,忙等会改为休眠,释放时要唤醒
- 锁的申请和释放,带来上下文切换,但是,在多处理器情况下,会 造成非常大的浪费
- 自旋锁是专为防止多处理器并发而引入的一种锁。

■ 自旋锁工作机理

- 自旋锁最多只能被一个内核任务持有,如果一个内核任务试图请求一个已被争用(已经被持有)的自旋锁,那么这个任务就会一直进行忙循环——旋转——等待锁重新可用。要是锁未被争用,请求它的内核任务便能立刻得到它并且继续进行
- 多核处理器中的busy waiting: 一个线程在一个处理器中自旋,另一个线程可以在另一个处理器中运行,表现形式则是用户进程可以继续工作
- 对于多核线程,预计线程等待锁的时间很短,短到持有自旋锁的时间小于两次上下文切换的时间,则使用自旋锁是划算的。

课堂讨论

 有了可以证明的软件方法解决同步问题 ,为什么还要硬件方法?

 为什么自旋锁对于单处理器系统不适合 ,而经常在多处理器系统中使用?

小结

- 关中断:
 - 对于单核处理器、非抢占式内核可行
 - 对于多核处理器、抢占式式内核不佳
- 原子指令方法
 - 复杂,需要硬件支持
- 互斥锁
 - 浪费CPU: 两次上下文切换
- 优先级翻转
 - 若进程间优先级: L<M<H, H依赖于L, L处于临界区, M抢占L, 则M影响了H

小作业-1:

小作业

1. V9, 6.3

2. 以及dekker算法讨论

```
enum bool {false, true};
bool flag [2] ={false, false};
int turn =0;
```

```
P0:
     do{
2.
       flag[0] = true;
       while (turn! = 0){
5.
            flag[0] = false;
6.
             while (flag[1]);
             flag[0] = true;
8.
9.
10.
       进程PO的临界区代码CSO;
11.
       turn = 1;
12.
       flag[0] = false;
13.
       进程PO的其他代码;
     } while (true)
14.
```

```
P1:
     do{
2.
        flag[1] = true;
3.
        while (turn ! = 1){
4.
5.
             flag[1] = false;
6.
             while (flag[0]);
7.
             flag[1] = true;
8.
9.
10.
        进程P1的临界区代码CS1;
11.
        turn = 0;
12.
        flaq[1] = false;
13.
        进程P1的其他代码;
     } while (true)
14.
```

第4章 进程同步

4.3 信号量

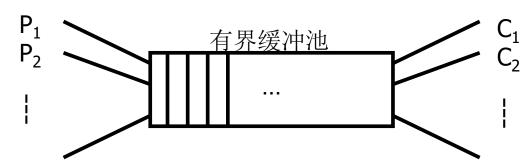
4.3 信号量: 同步问题的解决

- 一个经典的同步问题: 生产者与消费者
 - 著名的生产者--消费者问题是计算机操作系统中并发进程内在关系的一种抽象,是典型的进程同步问题。
 - 在操作系统中,生产者进程可以是计算进程、 发送进程;而消费者进程可以是打印进程、接 收进程等等。
 - 解决好生产者--消费者问题就解决好了一类 并发进程的同步问题。

生产者—消费者问题

问题描述 (有界缓冲区问题)

- 有n个生产者和m个消费者,连接在一个有k个单位缓冲区的有界缓冲上。
- 其中,生产者进程P_i和消费者进程C_i都是并发进程。
- 只要缓冲区未满,生产者P_i生产的产品就可投入缓冲区;
- 只要缓冲区不空,消费者进程C_j就可从缓冲区取走 并消耗产品。



 P_{m}

 C_k

生产者-消费者问题一种算法描述

```
常量k为缓冲区大小;
struct item nextp, nextc, buffer[k];
int in=0, out=0, counter = 0;
Producer i:
while (1){
  produce an item in nextp;
  /* 生产一个产品*/
  if (counter==k) sleep();
  /* 缓冲满时,生产者睡眠*/
  buffer[in]=nextp;
  /* 将一个产品放入缓冲区*/
  in=(in+1) % k;
  /* 指针推进*/
  counter++;
  /* 缓冲内产品数加1*/
  if (counter==1)
   wakeup(consumer);
   /* 之前缓冲是空的,加进一件产品后唤醒消费
者*/
```



```
Consumer j:
while (1){
  if (counter==0)
   sleep (); /* 缓冲区空消费者睡眠*/
  nextc=buffer[out];
  /*取一个产品到nextc*/
  out=(out+1)%k;
  /* 指针推进*/
  counter--;
 /* 取走一个产品,计数减1*/
  if (counter==k-1)
   wakeup(producer);
/* 此时缓冲取走了一件产品,唤醒生产者*/
  consume the item in nextc;
  /* 消耗产品*/
```



生产者-消费者问题一种算法描述

- 生产者和消费者进程对counter的交替执 行会使其结果不唯一
- 生产者和消费者进程的交替执行会导致 进程永远等待

- 前节种种软件方法解决临界区调度问题的缺点:
 - 对不能进入临界区的进程,采用忙式等待测试法,浪费CPU时间。
 - 将测试能否进入临界区的责任推给各个竞争的进程会 削弱系统的可靠性,加重了用户编程负担。
- 1965年, E. W. Dijkstra提出了新的同步工具:信号量和P、V操作

4.3.1 信号量的定义

- 信号量(semaphore)由两个成员(s, q)组成
 - 其中s是一个具有非负初值的整型变量
 - q是一个初始状态为空的队列。
- 除信号量的初值外,信号量的值仅能由P操作 (又称为wait操作)和V操作(又称为signal操作)改变。

P操作

■ 设S=(s, q)为一个信号量, P(S)执行时 主要完成下述动作:

```
S = S - 1;
If (s < 0) {</li>
设置进程状态为等待;
将进程放入信号量等待队列q;
转调度程序;
}
```

V操作

■ V(S)执行时主要完成下述动作:

```
    s=s+1;
    If(s≤0){

            将信号量等待队列q中的第一个进程移出;
            设置其状态为就绪状态并插入就绪队列;
            然后再返回原进程继续执行;
            }
```

几个重要含义

- 信号量中的整型变量s表示系统中某类资源的 数目。
- 当s>0时,
 - 该值等于在封锁进程之前对信号量S可施行的P操作数,
 - 等于S所代表的实际还可以使用的资源数
- 当s<0时,
 - 其绝对值等于登记排列在该信号量S队列之中等待 的进程个数,
 - 亦即恰好等于对信号量s实施P操作而被封锁起来并 进入信号量s队列的进程数

注意

- 通常,P操作意味着<mark>请求一个资源,V</mark>操作意味着<mark>释放</mark> 一个资源。
 - 在一定条件下,P操作代表使进程阻塞的操作,而V操作代表 唤醒阻塞进程的操作。
- P、V操作的原子性要求
 - 即,一个进程在信号量上操作时,不会有别的进程同时修改 该信号量。
 - 对于单处理器,可简单地在封锁中断的情况下执行
 - 对于多处理器环境,需要<mark>封锁所有处理器的中断</mark>,困难且影响性能,往往用swap()或自旋锁等方式加锁

信号量的另一种描述

```
typedef struct{
  int value;
  struct process *list;
  } semaphore;
wait(semaphore *S) {
 S->value--;
  if (S->value < 0) {
    add this process to S->list;
    block();
signal(semaphore *S) {
  S->value++;
  if (S->value <= 0) {
    remove a process P from S->list;
    wakeup(P);
```

4.3.2 利用信号量实现互斥

- 设S=(s,q)为两个进程P1、P2实现互斥的 信号量
 - s的初值应为1,即可用资源数目为1。

只需把临界区置于P(S)和V(S)之间, 即可实现两进程的互斥。

互斥访问临界区的描述

一个老问题……

■ 现有订票系统,x为存储某班次飞机剩余票数的存储区域

```
    A:
        B:
        R1=x;
        if (R1>=1) {
            R1--;
            R2--;
            x=R1;
            x=R2;
        {出票}
        }
```

一个信号量实现互斥的例子

改进订票系统:

```
A:
               B:
P(S);
                P(S);
R1=x;
                R2=x;
if (R1 > = 1) { if (R2 > = 1){
  R1--;
                R2--;
  x=R1;
                  x=R2;
                  V(S)
  V(S);
  {出票}
                  {無票}
  else{
                  else{
  V(S)
                   V(S)
  {提示无票}
                   {提示无票}
```

互斥信号量的取值范围

若2个进程共享一个临界资源,信号量的取值 范围是:

若没有进程使用临界资源 1

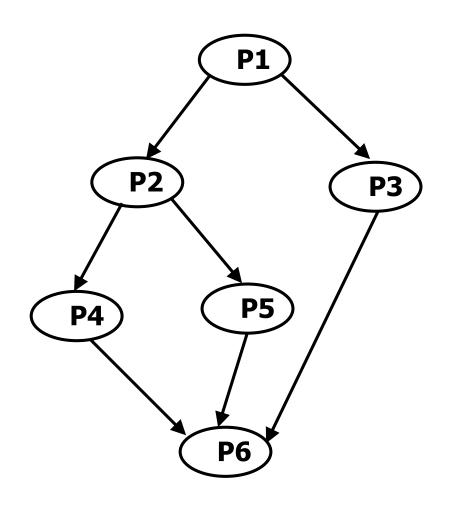
若只有1个进程使用临界资源 0

若1个进程使用临界资源,另1 -1 个进程等待使用临界资源

Q:若N个进程共享一个临界资源,其取值范围如何?

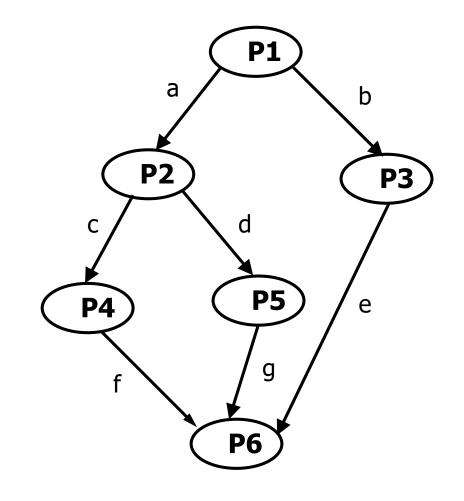
4.3.3 利用信号量实现前趋关系

P1、P2、P3、P4、P5、P6为一组合作进程,所不是的一个证据,是不可能是一个证据,是不可能是一个证据的。



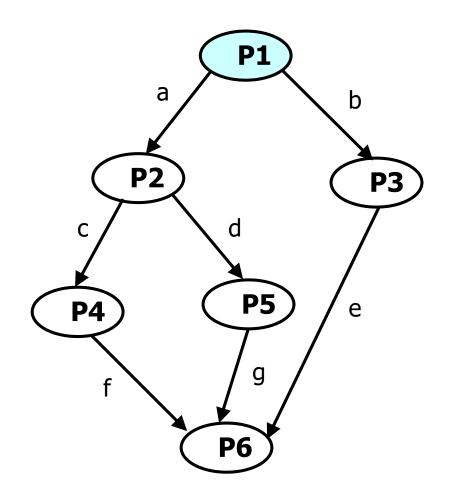
解法1

设七个同步信号 量a、b、c、d、 e、f、g分别表示 进程之间的前驱 关系,如图所示, 其初值均为0。这 六个进程的同步 描述如下:



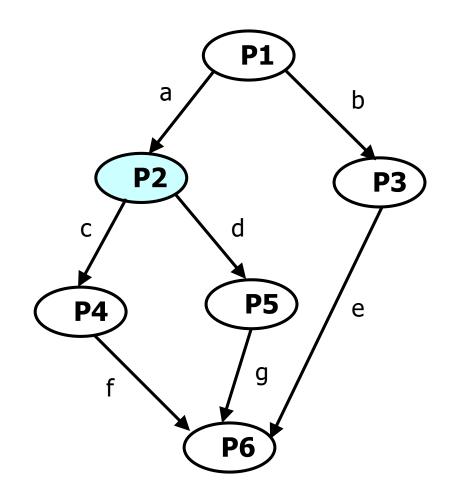
解法1 (1)

```
P1()
{
 执行P1的代码;
 v(a);
 v(b);
}
```



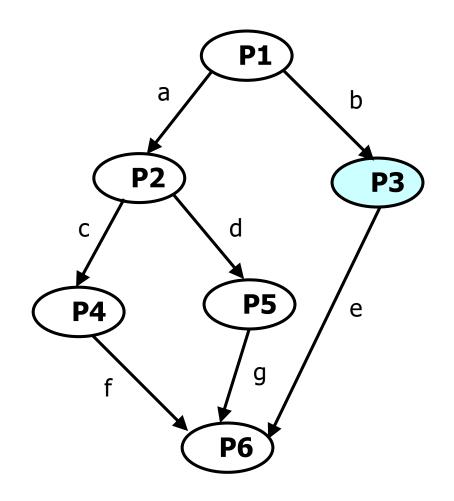
解法1 (2)

```
P2 ()
{
 p(a);
 执行P2的代码;
 v(c);
 v(d);
}
```



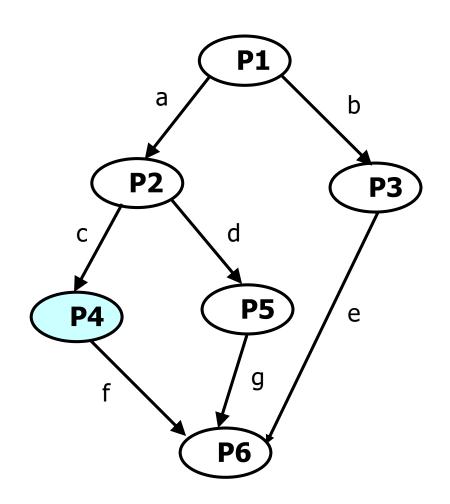
解法1 (3)

```
P3 ()
{
 p(b);
 执行P3的代码;
 v(e);
}
```



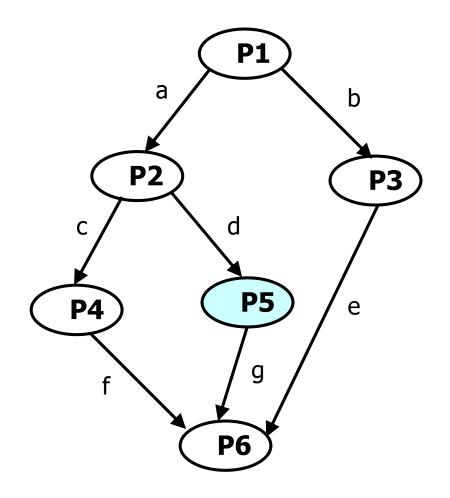
解法1 (4)

```
P4 ()
{
 p(c);
 执行P4的代码;
 v(f);
}
```



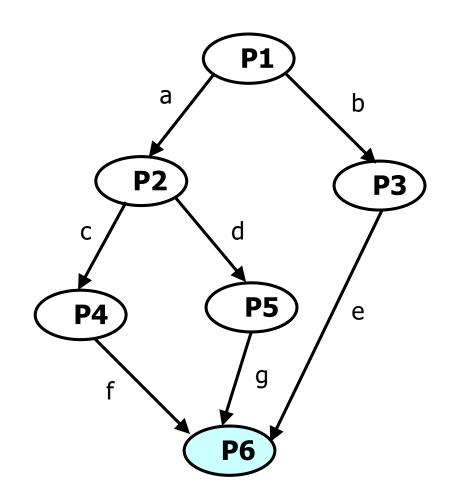
解法1 (5)

```
P5 ()
{
 p(d);
 执行P5的代码;
 v(g);
}
```



解法1 (6)

```
P6 ()
   p(e);
   p(f);
   p(g);
  执行P6的代码;
```

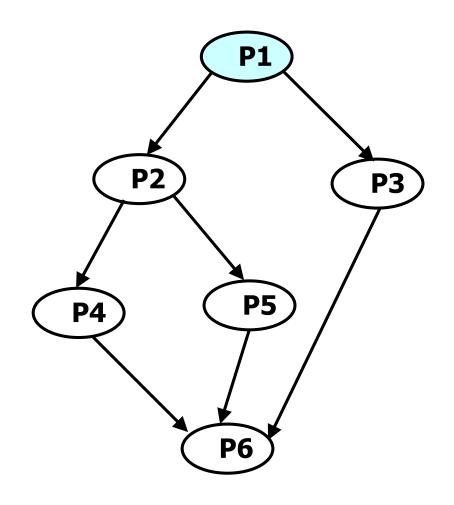


解法2

提示:设五个同步信号量f1、f2、f3、f4、f5分别表示进程P1、P2、P3、P4、P5是否执行完成,其初值均为0。这六个进程的同步描述如何?

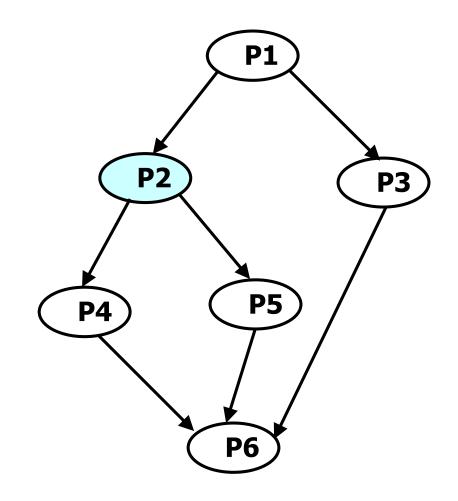
解法2 (1)

```
P1 ()
{
 执行P1的代码;
 v(f1);
 v(f1);
}
```



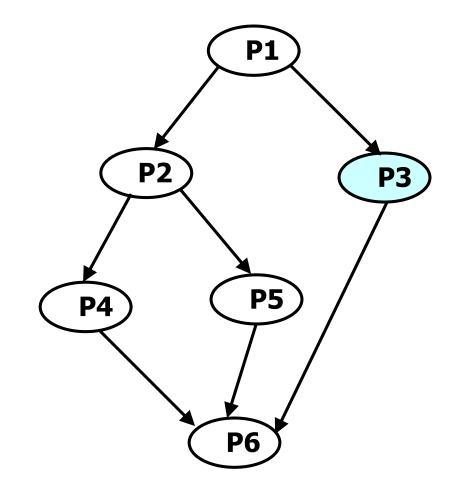
解法2 (2)

```
P2 ()
{
 p(f1);
 执行P2的代码;
 v(f2);
 v(f2);
}
```



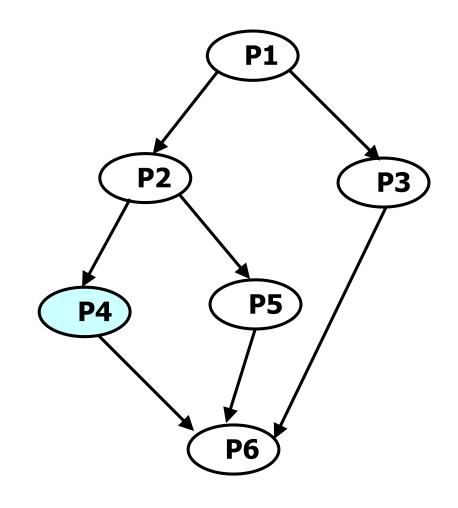
解法2 (3)

```
P3 ()
{
 p(f1);
 执行P3的代码;
 v(f3);
}
```



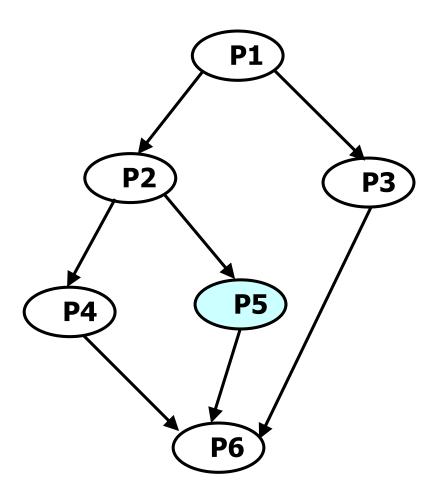
解法2 (4)

```
P4 ()
{
p(f2);
执行P4的代码;
v(f4);
}
```



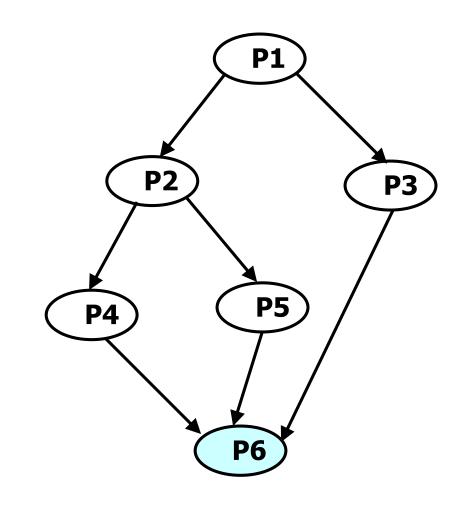
解法2 (5)

```
P5 ()
{
 p(f2);
 执行P5的代码;
 v(f5);
}
```



解法2 (6)

```
P6 ()
  p(f3);
  p(f4);
  p(f5);
  执行P6的代码;
```

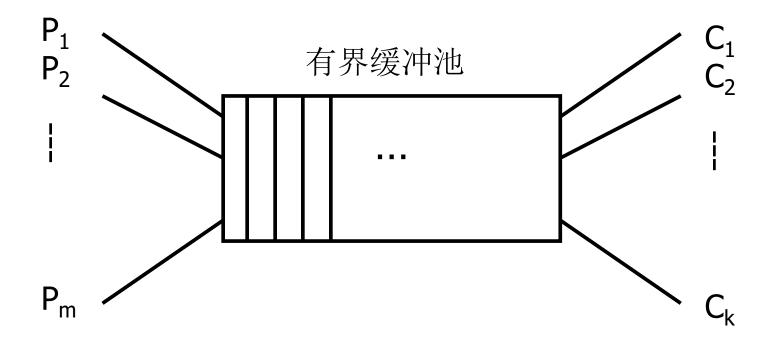


4.3.4 经典进程同步问题

多道程序环境中的进程同步是一个非常有趣的问题,吸引了很多学者研究,从而产生了一系列经典进程同步问题。

1、生产者—消费者问题

同步关系有: 当缓冲池满时生产者进程需等 待, 当缓冲池空时消费者进程需等待。诸进程应互斥使用缓冲池。



一个简化: 只有一个缓冲区

■ 设置两个同步信号量empty、full, 其初值分别为1、0

生产一个产品; p(empty); 将一个产品送入缓冲区; v(full); p (full); 从缓冲区中取一个产品; v (empty); 消费一个产品;

进一步:多个缓冲区n

- 设置两个同步信号量empty、full, 其初值分别为n、0。
- 有界缓冲池是一个临界资源,还需要设置一个互斥信号量mutex,其初值为1。
- 生产者—消费者问题的同步描述如下:

生产者

消费者

```
p(empty);
  p (mutex);
将一个产品送入缓冲区;
  v (mutex);
   v(full);
```

```
p (full);
  p (mutex);
从缓冲区中取一个产品;
  v (mutex);
  v (empty);
 消费一个产品;
```

注意:无论在生产者进程还是在消费者进程中,P操作的次序都不能颠倒,否则将可能造成死锁。



颠倒生产者进程中的P操作

当mutex=1, full=n, empty=0, 且生产者先执行时

mutex

```
生产一个产品;
 p(mutex);
 p(empty);
将一个产品送入缓冲区;
 v(mutex);
 v(full);
```

```
p (full);
  p (mutex);
从缓冲区中取一个产品;
  v (mutex);
  v (empty);
 消费一个产品;
```

full

empty

2.读者—写者问题

- 一个数据对象(如文件或记录)可以被多个并发进程所共享
- 其中有些进程只要求读数据对象的内容——读者
- 而另一些进程则要求修改或写数据对象的内容——写者
- 允许多个读进程同时读此数据对象
- 但是一个写进程不能与其他进程(不管是写进程还是读进程) 同时访问此数据对象

读者—写者问题分类

■ 读者优先:

当存在一个读者时候,读者优先,写者会长时间等待。

■ 写者优先:

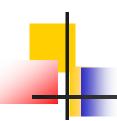
- 当写者提出存取共享对象的要求后,已经开始读的 进程让其读完,但不允许新读者进入。
- 写者结束时,判断是否有写者等,有则优先写者

■ 读写者公平:

- 按提出请求的顺序先来先服务
- 读者前面无写者等待时,可进入
- 读者前面有写者等待时,等待

用信号量解决读者优先问题

- 为解决读者优先问题,应设置两个信号量和一个共享变量:
 - 互斥信号量rmutex,用于使读进程互斥地访问共享变量readcount,其初值为1;
 - 共享变量readcount,用于记录当前正在读数据 集的读进程数目,初值为0。
 - 写互斥信号量wmutex,用于实现写进程与读进程的互斥以及写进程与写进程的互斥,其初值为1;



```
p(rmutex);
if (readcount==0) p(wmutex);
readcount++;
v(rmutex);
读数据集;
p(rmutex);
readcount--;
if (readcount==0) v(wmutex);
v(rmutex);
```

```
p(wmutex);
写数据集;
v(wmutex);
```

对读者优先问题的理解

- ■请注意对信号量rmutex意义的理解。
- rmutex是一个互斥信号量,用于使读进程互斥地访问共享变量readcount。该信号量并不表示读进程的数目,表示读进程数目的是共享变量readcount。

- 问题首次讨论于:
 - P.J. Courtois, F. Heymans. Concurrent Control with "Readers" and "Writers".
 Communications of the ACM, 1971.

写者优先

- 应该满足的要求
 - 多个读者可以同时进行读;
 - 写者必须互斥
 - 只允许一个写者写,不能读者写者同时进行
 - 写者优先于读者
 - 一旦有写者,则后续读者必须等待,在唤醒时优先考虑写者,直到最后一个写者完成
 - 对于已经开始的读者让其读完,对于未开始的读者让其等待
 - 如果一堆读者排在写者前面,应该按照排队顺序 工作,or写者能插队吗?

这个对吗?

```
Reader()
{
    P(mutexReadCount);
    P(r);
    readcount ++;
    V(r);
    V(mutexReadCount);
    reading is performed....
    P(mutexReadCount);
    readcount --;
    V(mutexReadCount);
}
```

```
Writer()
    P(mutexWriteCount);
    //写者入队列
    writecount ++:
    //若为第一个写者,阻止后续的读者
    if (writecount==1) P(r);
    V(mutexWriteCount);
    //互斥其他的写者
    P(w);
    writing is performed...
    V(w);
    P(mutexWriteCount);
    writecount --;
    if(writecount == 0) V(r);
    V(mutexWriteCount);
```

这个对吗?

```
Reader()
    P(mutexReadCount);
    P(r);
   readcount ++;
    //若为第一个读者, 互斥写者
    if (readcount==1) P(w);
   V(r);
    V(mutexReadCount);
    reading is performed....
    P(mutexReadCount);
    readcount --;
    //若当前读者为最后一个,则唤醒写者
    if (readcount==0) V(w);
    V(mutexReadCount);
```

```
Writer()
    P(mutexWriteCount);
    //写者入队列
    writecount ++;
    //若为第一个写者,阻止后续的读者
    if (writecount==1) P(r);
    V(mutexWriteCount);
    //互斥其他的写者
    P(w);
    writing is performed...
    V(w);
    P(mutexWriteCount);
    writecount --;
    if(writecount == 0) V(r);
    V(mutexWriteCount);
```

.

这个还有问题吗?

```
Reader()
   P(r);
   P(mutexReadCount);
   readcount ++;
   //若为第一个读者, 互斥写者
   if (readcount==1) P(w);
   V(mutexReadCount);
   V(r);
    reading is performed....
   P(mutexReadCount);
   readcount --:
    //若当前读者为最后一个,则唤醒写者
   if (readcount==0) V(w);
   V(mutexReadCount);
```

```
Writer()
    P(mutexWriteCount);
    //写者入队列
    writecount ++:
    //若为第一个写者,阻止后续的读者
    if (writecount==1) P(r);
    V(mutexWriteCount);
    //互斥其他的写者
    P(w);
    writing is performed...
    V(w);
    P(mutexWriteCount);
    writecount --:
    if(writecount == 0) V(r);
    V(mutexWriteCount);
```

写者优先解法

变量int readcount=0,writecount = 0。 设置5个信号量: mutexReadCount, mutexWriteCount, mutexPriority, r, w.

```
Reader()
                                                  Writer()
    P(mutexPriority);
                                                      P(mutexWriteCount);
                                                      //写者入队列
    P(r);
    P(mutexReadCount);
                                                      writecount ++:
    readcount ++;
                                                      //若为第一个写者,阻止后续的读者
    //若为第一个读者,互斥写者
                                                      if (writecount==1) P(r);
    if (readcount==1) P(w);
                                                      V(mutexWriteCount);
                                                      //互斥其他的写者
    V(mutexReadCount);
   V(r);
                                                      P(w);
   V(mutexPriority);
                                                      writing is performed...
    reading is performed....
                                                      V(w);
    P(mutexReadCount);
                                                      P(mutexWriteCount);
    readcount --:
                                                      writecount --:
    //若当前读者为最后一个,则唤醒写者
                                                      if(writecount == 0) V(r);
    if (readcount==0) V(w);
                                                      V(mutexWriteCount);
    V(mutexReadCount);
```

思考一下,如下算法是怎样效果呢?

```
p(w)
p(rmutex);
if (readcount==0) p(wmutex);
readcount++;
v(rmutex);
V(W)
读数据集;
p(rmutex);
readcount--;
if (readcount==0) v(wmutex);
v(rmutex);
```

```
p(w)
p(wmutex);
写数据集;
v(wmutex);
v(w);
```

思考一下,如下算法又是怎样效果呢?

```
p(w)
p(rmutex);
if (readcount==0) p(wmutex);
readcount++;
v(rmutex);
V(W)
读数据集;
p(rmutex);
readcount--;
if (readcount==0) v(wmutex);
v(rmutex);
```

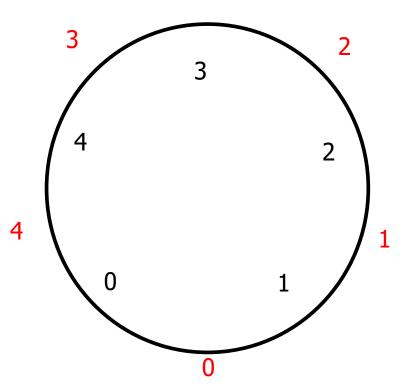
```
p(w)
p(wmutex);
v(w);
写数据集;
v(wmutex);
```

3. 哲学家进餐问题

- 哲学家进餐问题描述:
 - 有五个哲学家,他们的生活方式是交替地进行思考和进餐,
 - 哲学家们共用一张圆桌,分别坐在周围的五张椅子上,在 圆桌上有一盆米饭和五支筷子,
 - 平时哲学家进行思考,饥饿时便试图取其左、右最靠近他的筷子,只有在他拿到两支筷子时才能进餐,
 - 进餐完毕,放下筷子又继续思考。

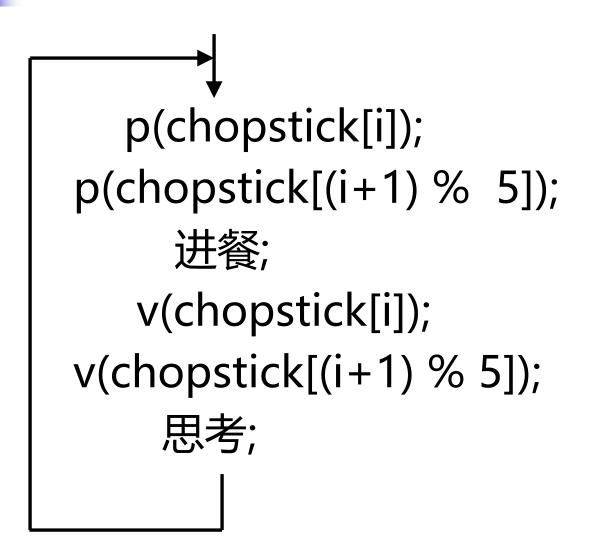


用信号量解决哲学家进餐问题



- 用五支筷子的信号量构 成信号量数组:
 - semaphore chopstick[5];
 - 所有信号量初值为1,

某哲学家活动的简单描述

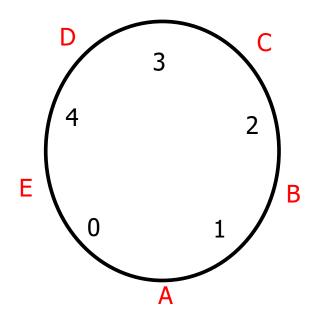


算法描述存在的问题

- 上述算法有可能引起死锁
 - 如所有人都并发的先拿起右边的筷子,然后再拿起 左边的筷子。
- 对于这样的死锁问题有如下办法解决:
 - 破坏请求保持条件
 - 只有一个哲学家两个筷子都可用时候,才能拿起筷子,即 在临界区里面拿起两根筷子
 - 引入一个服务生来监管
 - 破坏环路
 - 至多4个哲学家同时进餐
 - 采用非对称方案, 奇数号哲学家先拿左筷子再拿右筷子, 偶数号哲学家相反。
 - 按照一定顺序获取资源,按照相反顺序释放资源。破坏环路 {资源分级法}

服务生解法

- 引入一个餐厅服务生,哲学家必须经过 他的允许才能拿起筷子
- 服务生:了解当前筷子使用情况,能够 正确判断,避免死锁



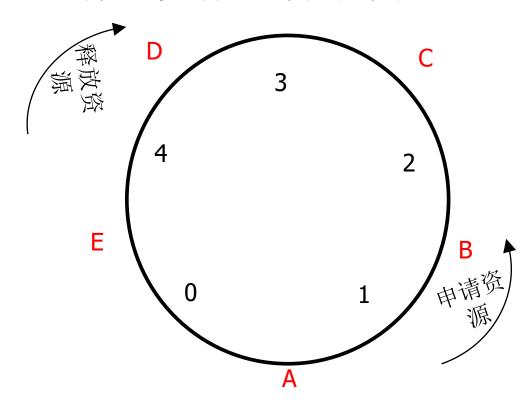
资源分级解法

为资源分配一个偏序关系

■ 获取:按照这一顺序

■ 释放:按照相反顺序

保证不会有两个无关资源同时被同一项工作所需要。



资源分级解法

- 筷子编号为#0、.....、#4
- 取筷子原则:每个哲学家总先拿起左右两边编号较低的筷子,再拿编号较高的。
- 放筷子规则:用完餐后,他总是先放下编号较高的筷子,再放下编号较低的。
- 为什么不会产生死锁?
 - 当A—E号哲学家同时拿起他们手边编号较低的筷子时(#0—3),则只有#4筷子留在桌上
 - 此时A—E之一能拿起最高号的筷子,吃完,并放下 筷子,从而让其他哲学家继续。

■ 不足:

- 尽管资源分级能避免死锁,但这种策略并不 总是实用的,特别是当所需资源的列表并不 是事先知道的时候,且效率存在问题。
- 例如,假设一个工作单元拿着资源3和5,并决定需要资源2,则必须先要释放5,之后释放3,才能得到2,之后必须重新按顺序获取3和5。



Chandy/Misra解法

- 筷子:每只筷子都是"干净的"或者"脏的"。
- 初始分配:
 - 对每一对竞争一个资源的哲学家,就新拿一个筷子,并分给标号较低的哲学家。最初每一只筷子都是脏。
- 请求:
 - 当一位哲学家要使用资源时,他必须从与他竞争的邻居那里得到。对每支他当前没有的筷子,他都发送一个请求
- 响应:
 - 当拥有筷子的哲学家收到请求时,如果筷子是干净的,那么他继续留着,否则就擦干净并交出筷子
- 吃饭:
 - 当某个哲学家拥有两个筷子,就能吃东西
 - 吃东西后,他的筷子就变脏了
 - 如果另一个哲学家之前请求过其中的筷子,那他就擦干净并交出筷子。

Chandy, K.M.; Misra, J. . The Drinking Philosophers Problem. ACM Transactions on Programming Languages and Systems. 1984

4.睡眠的理发师问题

- 理发店里有一位理发师,一把理发椅和N 把供等候理发顾客坐的椅子。
- 如果没有顾客,理发师睡眠,当一个顾客到来时叫醒理发师;
- 若理发师正在理发时又有顾客来,那么有空椅子就坐下,否则离开理发店。

用信号量解决睡眠的理发师问题

- 为解决睡眠的理发师问题,应使用三个信号 量:
 - Customers记录等候理发的顾客数(不包括正在理发的顾客);初值为0
 - barbers记录正在等候理发师的顾客数;初值为0
 - mutex用于互斥访问count。初值为1
- 一个变量:
 - 变量count记录等候的顾客数,它是customers 的一份拷贝。之所以使用count是因为无法读取 信号量的当前值。

问题描述

```
Baber(){
  while(true){
  //是否有等候的顾客,若无顾客,理发师睡眠
      p(customers);
  //若有顾客,则进入临界区
      p(mutex);
  //等待中的顾客数减1
      count--;
  //理发师发出通知,已经准备好为顾客理发
      v(barbers);
  //退出临界区
      v(mutex);
      cut_hair();
```

```
Customer-i (){
  p(mutex);
  //判断是否有空椅子
  if(count < N)
      //等待顾客数加1
      count++;
      //唤醒理发师
      v(customers);
      //退出临界区
      v(mutex);
     //等待理发师准备好,如果理发师忙,
  顾客等待
      p(barbers);
      get haircut();
  else
  //无空椅子人满了,顾客离开
  v(mutex);
```

讨论:

■ 1.为什么在baber中,P(mutex)不可以 在p(customer)之前出现?

2.为什么在baber中, v(mutex)不可以在v(barbers)之前?

■ 3.为什么在customer中, v(customers) 与count++要放到mutex保护中



```
Baber(){
  while(true){
      p(mutex);
      p(customers);
      count--;
      v(barbers);
      v(mutex);
      cut hair();
```

```
Customer-i (){
  p(mutex);
  if(count < N)
     count++;
     v(customers);
     v(mutex);
      p(barbers);
     get haircut();
 else
     v(mutex);
```



1122 为什么在barber中,v(mutex)和v(babers)不能反过来?

```
Baber(){
  while(true){
      p(customers);
      p(mutex);
      count--;
      v(mutex);
      v(barbers);
      cut hair();
```

```
Customer-i (){
 p(mutex);
  if(count < N)
     count++;
     v(customers);
     v(mutex);
     p(barbers);
     get haircut();
 else
     v(mutex);
```



为什么在customer中,v(customers)与count++要放到mutex保护中

```
Baber(){
  while(true){
      p(customers);
      p(mutex);
      count--;
      v(barbers);
      v(mutex);
      cut hair();
```

```
Customer-i (){
 p(mutex);
  if(count < N)
      count++;
     v(mutex);
     v(customers);
      p(barbers);
      get haircut();
 else
     v(mutex);
```

讨论:

```
Baber(){
  while(true){
      p(customers);
      p(mutex);
      count--;
      v(barbers);
      v(mutex);
      cut hair();
```

```
Customer-i (){
 p(mutex);
  if(count < N)
     count++;
     v(customers);
     v(mutex);
     p(barbers);
     get haircut();
 else
     v(mutex);
```

利用信号量解决同步问题的思路

- 理清同步与互斥关系
 - 哪些资源及对象需要互斥访问
 - 哪些资源的访问顺序对进程调度有制约关系
 - 同步信号量要表示出资源的等待条件及数目
 - P操作内包含等待: V操作内包含唤醒
 - 依多个访问顺序约束,同类资源可设置多个信号量
 - 生产者消费者问题中的empty和full
 - 一定要注意互斥量与同步信号量的顺序
 - 同步P优先于互斥P
 - 信号量的操作只能为PV,切记不要直接取指和赋值
 - 可设置副本,如理发师问题中的count 和customers

- 1. 有P1、P2、P3三类进程(每类进程都有K个)共享一组表格F(F有N个), P1对F只读不写, P2对F只写不读, P3对F先读后写。进程可同时读同一个Fi(0≤i≤N);但有进程写时,其他进程不能读和写。
 - 用信号量和P、V操作给出方案
 - 对方案的正确性进行分析说明
 - 对访问的公平性进行分析

- 2.三组进程P1(K个, K>1)、P2(1个)、P3(1个)、互斥使用一个包含N(N>1)个单元的缓冲区buf1, P2-1、P3-1、P4(各有1个)执行定期统计
 - P1每次用produce(),生成一个正整数并用put()送入缓冲区buf1某一空单元中,循环访问缓冲区
 - P2每次用getodd()从buf1缓冲区取出一个奇数,放到自己私有缓冲区buf2中(缓冲区长度为M>1),然后由P2-1(1个)进程读取P2的私有缓冲区,使用countodd()统计奇数个数
 - P3每次用geteven()从buf1缓冲区中取出一个偶数, 放到自己私有缓冲区buf3中(缓冲区长度为M>1), 然后由P3-1(1个)进程读取P3的私有缓冲区, 使用counteven()统计偶数个数
 - P4在P2-1、P3-1产生一个统计值后,就输出一个包含统计时间的结果
 - 请用信号量机制实现这几个进程的同步与互斥活动,并说明 所定义的信号量含义。

3. 独木桥问题

- ① 独木桥只允许一台汽车过河,当车到达桥头时,如果桥上无车,则可上桥,否则车在桥头等待,直到桥上无车。使用 PV操作解决该问题。
- ② 如果独木桥允许多台车同方向过河,当车到达桥头时,如果 桥上只有同方向车且不超过N台,或者桥上无车,则可上桥 通过,否则等待,直到满足上桥条件。使用PV操作解决该 问题。

■ 4.红黑客过河问题

有红客和黑客两组人员需要过河。河上有船,但是每次只能乘坐4人,且每次乘客满员时才能开船,到河对岸后空船返回。但船上乘客不能同时有3个红客、1个黑客或者1个红客、3个黑客的组合。(其他组合安全)。请编写程序,用PV操作解决红客、黑客过河的问题。

大作业

1. 参考V9版,课后编程项目,针对读者/写者、生产者/消费者、哲学家问题、理发师(or睡觉助教),选择一个实现,要求使用Pthread和 Windows 线程API实现

.

第4章 进程同步

4.4 管程

4.4 管程

- 信号量的同步操作分散在各进程中不便于管理, 还可能导致系统死锁。如:生产者消费者问题 中将P颠倒可能死锁。
- 为此Dijkstra于1971年提出:把所有进程对某一种临界资源的同步操作都集中起来,构成一个所谓的秘书进程。凡要访问该临界资源的进程,都需先报告秘书,由秘书来实现诸进程对同一临界资源的互斥使用。

有了管程的优势

- 把分散在各进程中的临界区集中起来进行管理;
- 防止进程有意或无意的违法同步操作,
- 便于用高级语言来书写程序,也便于程序正确性验证。

_4.4.1 管程定义

 Hansen为管程(Monitor)所下的定义是: 管程定义了一个数据结构和能为并发进 程所执行的一组操作,这组操作能同步 进程和改变管程中的数据。

管程的构成

- 局部于管程的共享数据结构
- 对共享数据结构进行操作的一组函数
- 对局部于管程的数据设置初始值的语句

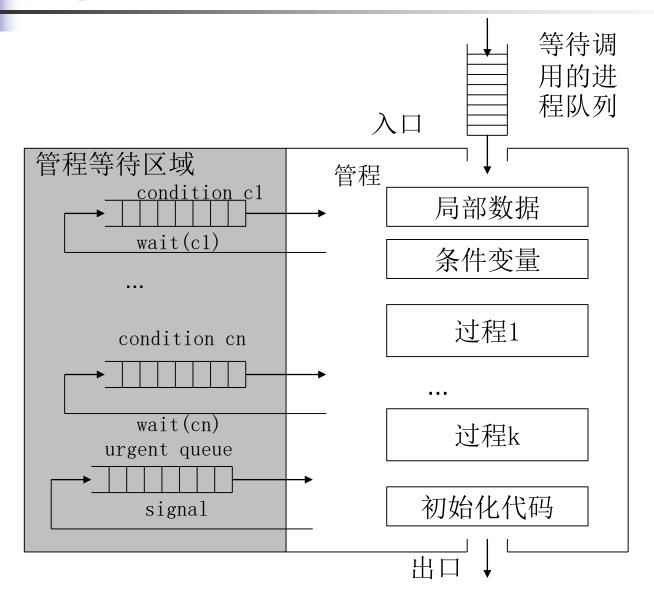
管程的语法

```
type 管程名=monitor {
 局部变量说明;
 条件变量说明:
 初始化语句:
define 管程内定义的,管程外可调用的过程或函数名列表;
use 管程外定义的,管程内将调用的过程或函数名列表;
过程名/函数名(形式参数表) {
 <过程/函数体>;
过程名/函数名(形式参数表) {
 <过程/函数体>;
```

管程的基本特性

- 1. 安全性
 - 管程内的局部数据<mark>只能</mark>被该管程内的函数所访问。
- 2. 共享性
 - 进程对管程的访问**都可以通过**共享相同的管程函数来实现。
- 3. 互斥性:
 - **每次仅允许一个**进程在管程内执行某个函数,共享资源的进程可以访问管程,但是**只有至多一个**调用者**真正**进入管程,其他调用者必须等待。
- 4. 透明性
 - 管程是一个语言成分,所以管程的互斥访问完全由编译程序在编译时自动添加上,**无需**程序员关心,而且保证正确。

管程的结构



管程中涉及的同步等问题(1)

- 条件变量:
 - 当调用管程过程的进程无法运行时,用于阻塞进程的一种特殊的信号量。相应地,还应该设置同步等待原语与同步唤醒原语。
- 同步原语C.wait与C.Signal
 - 当一个调用管程过程的进程发现无法继续时,它在某些条件变量condition上执行C.wait,这个动作引起调用进程阻塞
 - 另一个进程可以通过对同一个条件变量 condition上执行同步原语C.signal操作来唤醒等 待进程。

条件变量

- 条件变量的基本定义形式为: condition: x,y;
- 注意:条件变量与P、V操作中信号量是不同的
 - P、V操作内部会对信号量进行计数,通过对累计值的管理,实现对进程间的关系进行有效管理
 - 条件变量只是一种简单的信号量,只进行维护等待队列的操作,不进行计数,没有累计值。若条件变量上没有等待的进程,该信号量会被丢弃,即signal触发一个空操作。

管程中涉及的同步等问题 (2)

- 使用signal释放等待进程时,可能造成调用signal的 进程在管程中,被恢复的那个进程也在管程中,即出 现两个进程同时停留在管程内
- 解决方法:
 - 1. 执行signal的进程等待,直到被释放进程退出管程或等待另一个条件
 - 2. 被释放进程等待,直到执行signal的进程退出管程或等待另一个条件
- 霍尔(Tony Hoare)的方法采用了第一种办法
- 汉森选择了两者的折衷,规定管程中的过程所执行的 signal操作是过程体的最后一个操作

4.4.2 Hoare方法管程的实现

■ 霍尔方法的原则:

- 使用P和V操作原语来实现外部进程对管程中过程的 互斥调用,并实现对共享资源互斥使用的管理。
- 当signal唤醒另一个进程时候,调用了signal操作的进程进入等待,直到其他进程操作完成退出,或者由于其他条件而等待。
- wait和signal操作可被设计成可以中断的过程。

Hoare管程的数据结构

1.mutex:实现管程互斥调用所需信号量

- ①当进程调用管程时候,管程将使用内部的互斥变量 mutex(初值为1),实现仅一个进程能调用管程中的 过程运行。
- ②进程调用管程中的任何过程时,应执行P(mutex); 进程<mark>退出管程</mark>时应执行V(mutex)开放管程,以便让 其他调用者进入。
- ③为了使得调用进程在等待资源期间,其他进程能够访问管程,在<mark>管程条件变量</mark>所对应的的wait操作过程中,需要调用V(mutex),开放管程的使用,从而提高资源的使用,有利于资源的释放。

Hoare管程的数据结构(Cont.)

- 2.x_sem和x_count:实现管程条件变量wait和 signal操作所需信号量
 - ①管程调用进程由于等待资源,会调用条件变量的 wait操作,进入等待队列。
 - ②x_sem用于条件变量wait和signal所需的信号量(初值为0,从而当wait内部调用P操作即进入等待)
 - ③由于x_sem<0,仍然可以将进程转等待,因此可能有多个进程等待资源,故需要一个计数器知道多少进程车等待,为x_count(初值为0)。
 - ④执行signal时候,需要让等待的某个进程立即恢复 ,而其他进程不允许进入,因此需要用到V(x_sem)

Hoare管程的数据结构(Cont.)

- 3. next, next count:处理signal操作时,唤醒其他进程,而自身进入等待的信号量
 - ①对于管程,发出signal操作后,立即通过V(x_sem) 释放一个等待的进程,并且使用P(next)将自己阻 塞,进入等待
 - ②该进程直到被释放的进程退出管道时候,被 V(next)唤醒(故Leave中有V(next));
 - ③或者该进程由于等待其他条件,而进入等待时被 V(next)唤醒(故wait中有V(next))。
 - ④进程在退出管道时候,需要检查是否有其他进程由于signal而等待于next上,若有则唤醒。因此,需要一个计数器next_count来记录next上等待的进程数。

Hoare管程的定义

```
typedef struct InterfaceModule{
      semaphore mutex;
                          //调用管程互斥信号量
                          //signal操作等待信号量
      semaphore next;
                          //next上等待进程数
      int next count;
mutex=1;next=0;next_count=0; //初始化语句
void enter(InterfaceModule &IM){
  P(IM.mutex);
void leave(InterfaceModule &IM){
  if (IM.next count>0)
      V(IM.next);
                           //唤醒因为signal操作而等待的进程
  else
                           //唤醒因访问管程而等待的进程
      V(IM.mutex);
```

Hoare管程的定义 (Cont.)

```
void wait(semaphore &x sem,int &x count, Interface &IM){
  x count++;
  if (IM.next count>0)
        V(IM.next);
                        //自身等待,将因signal而休眠的进程释放一个
  else
        V(IM.mutex);
                                //否则开放管程
   P(x \text{ sem});
                                //自己阻塞自己
                        //将来被唤醒时候,执行等待资源数减少一个
  x count--;
void signal(semaphore &x sem,int &x count, Interface &IM){
   if (x count>0) //判断是否有等待资源的进程
        IM.next count++;
                                //因为signal休眠的进程数+1
                                //唤醒一个等待资源进程
        V(x \text{ sem});
        P(IM.next);
                                //因为发signal唤醒别的进程自己阻塞
                                //等将来被唤醒时候,因signal休眠数-1
        IM.next count--;
```

基于Hoare方法的哲学家问题解决

- 用三种不同状态表示哲学家的活动: 进餐、饥饿、 思考。 (thinking, hungry, eating) state[5];
- 为每个哲学家设置一个条件变量self(i),当哲学家饥饿又不能获得筷子时,用self来阻塞自己:
- 管程设置三个函数: pickup取筷子, putdown放筷子, test测试是否具备进餐条件。

基于Hoare方法的哲学家问题解决

```
type dining_philosophers=monitor
   enum {thinking, hungry, eating} state[5]; //哲学家的状态
   semaphore self[5];
                                     //条件变量
   int self count[5];
                                     //共享变量
   InterfaceModule IM;
   for (int i=0;i<5;i++) state[i] = thinking;
   define pickup, putdown;
   use enter, leave, wait, signal;
void pickup(int i){
   enter(IM);
   state[i]=hungry;
   test[i];
   if (state[i]!=eating);
         wait(self[i],self_count[i],IM);
   leave(IM);
```

基于Hoare方法的哲学家问题解决

```
void putdown(int i){
   enter(IM);
   state[i]=thinking;
   test[(i-1)%5];
   test[(i+1)\%5];
   leave(IM);
void test (int k){
   if (state[(k-1)%5]!=eating)&&(state[k]==hungry)
         &&(state[(k+1)%5]!=eating)){
         state[k] = eating;
         signal(self[k],self_count[k],IM);
```



```
main()
{
    cobegin
        philosopher(0);
    philosopher(1);
    philosopher(2);
    philosopher(3);
    philosopher(4);
    coend
}

    void philosopher(int i)
{
        while(true)
        {
            Thinking;
            dining-philosophers.pickup(i);
            Eating;
            dining-philosophers.putdown(i);
        }
}
```

本章小节

- 临界资源访问的原则
- 同步与互斥的定义
- 互斥的实现方法(软件、硬件、锁)
- 信号量的定义
- 信号量解决经典问题
- 管程的基本概念



作业整理: 小作业

- 1. V9, 6.3
- 有P1、P2、P3三类进程(每类进程都有K个)共享一组表格F(F有N个), P1对F只读不写, P2对F只写不读, P3对F先读后写。进程可同时读同一个Fi(0≤i≤N); 但有进程写时,其他进程不能读和写。
 - 用信号量和P、V操作给出方案
 - 对方案的正确性进行分析说明
 - 对访问的公平性进行分析

一小作业

- 3.三组进程P1 (K个, K>1) 、P2 (1个) 、P3 (1个) 、互斥使用一个包含N(N>1)个单元的缓冲区buf1 , P2-1、P3-1、P4 (各有1个) 执行定期统计
 - P1每次用produce(),生成一个正整数并用put()送入缓冲区buf1某一空单元中,循环访问缓冲区
 - P2每次用getodd()从buf1缓冲区取出一个奇数,放到自己私有缓冲区buf2中(缓冲区长度为M>1),然后由P2-1(1个)进程读取P2的私有缓冲区,使用countodd()统计奇数个数
 - P3每次用geteven()从buf1缓冲区中取出一个偶数, 放到自己私有缓冲区buf3中(缓冲区长度为M>1), 然后由P3-1(1个)进程读取P3的私有缓冲区, 使用counteven()统计偶数个数
 - P4在P2-1、P3-1各产生一个统计值后,就输出一个包含统计时间的结果
 - 请用信号量机制实现这几个进程的同步与互斥活动,并说明 所定义的信号量含义。

4. 独木桥问题

- 独木桥只允许一台汽车过河,当车到达桥头时,如果桥上无车,则可上桥,否则车在桥头等待,直到桥上无车。使用PV操作解决该问题。
- 如果独木桥允许多台车同方向过河,当车到达桥头时,如果 桥上只有同方向车且不超过N台,或者桥上无车,则可上桥 通过,否则等待,直到满足上桥条件。使用PV操作解决该 问题。

■ 5.红黑客过河问题

有红客和黑客两组人员需要过河。河上有船,但是每次只能乘坐4人,且每次乘客满员时才能开船,到河对岸后空船返回。但船上乘客不能同时有3个红客、1个黑客或者1个红客、3个黑客的组合。(其他组合安全)。请编写程序,用PV操作解决红客、黑客过河的问题。

大作业

1. 参考V9版,课后编程项目,针对读者/写者、生产者/ 消费者、哲学家问题、理发师(or睡觉助教),选择 一个实现,要求使用Pthreads 和 Windows 线程API 实现